

Projet1 : Data Warehouse & BI

I. Objectifs du projet N1 : Création d'un Data Warehouse

1. Intégration des sources hétérogènes

- Connecter le Superstore Dataset (CSV/Excel) et la base gestionstock.
- Traiter les différences de formats, unités, noms de colonnes, types de données.

2. Conception d'un modèle de Data Warehouse

- Choisir un schéma adapté : étoile, flocon, ou Data Vault selon le besoin.
- Identifier les dimensions et faits :

3. ETL (Extract – Transform – Load)

- Extraction : Lire les données CSV et la base relationnelle.
- Transformation :
 - Nettoyage : valeurs manquantes, doublons, incohérences.
 - Uniformisation : format des dates, des codes produits, des unités.
 - Calculs supplémentaires : marge, stock disponible, etc.
- Chargement : Insérer dans les tables du Data Warehouse.

4. Historisation et gestion des dimensions lentes (SCD)

- Par exemple : suivi des changements de prix ou de stock dans le temps.

5. Préparation pour l'analyse décisionnelle

- Créer des vues ou cubes OLAP pour faciliter les analyses.

Outils :

Talend Open Studio (ou Talend Data Integration) ou équivalent.

SGBD relationnel : PostgreSQL ou autre

II. Sources de données :

1- Superstore Dataset : <https://www.kaggle.com/datasets/vivek468/superstore-dataset-final?resource=download>

Ou : <https://drive.google.com/file/d/1LTuoNy6KCm-CRdPzhjC19B8wHD6-7U54/view?usp=sharing>

Le fichier **Superstore.csv** contient des données de ventes d'une entreprise X.

Il enregistre les transactions commerciales réalisées par des clients, incluant les informations sur :

- les commandes,
- les clients,
- les produits,
- les livraisons,
- et les performances financières (ventes, remises, profits).

2- Base de données « GestionStock » :

https://drive.google.com/file/d/1uKRP2BP5MxJFV8ocugF3_taBEhalYITl/view?usp=sharing

La base de données **GestionStock** est conçue pour compléter le **Superstore Dataset** en intégrant les informations sur le **stock**, les **fournisseurs** et les **entrepôts**.

Table	Description
Fournisseurs	Liste des fournisseurs avec leurs coordonnées
Entrepôts (lieux de stockage)	Liste des entrepôts et leur région
Stock	Quantité en stock de chaque produit, lié au fournisseur et à l'entrepôt

- Chaque produit en stock est lié à un fournisseur (Fournisseurs) et à un entrepôt (Entrepôts).
- Le Stock est relié aux produits du Superstore Dataset via Product ID.

III. Aspects à analyser après la création du Data Warehouse

1. Analyse des ventes

- Total des **ventes (Sales)** par **produit**, **sous-catégorie**, **catégorie** et **région**.
- Ventes par **segment de client** (Consumer, Corporate, Home Office) et par **ville** ou **État**.
- Évolution des ventes dans le temps (**Order Date**) : par mois, trimestre ou année.

2. Analyse de la rentabilité

- Total du **profit** et calcul de la **marge** par produit, sous-catégorie, catégorie et région.
- Identifier les produits à **fort chiffre d'affaires** mais **faible marge**.
- Impact des **remises (Discount)** sur le profit et la marge.

3. Gestion des stocks et approvisionnements

- Quantité disponible par **produit** et par **lieu de stockage**.
- Produits à **rotation rapide** vs **lente**.
- Alertes pour **produits en rupture de stock** ou quantité faible.
- Analyse des mouvements de stock par **fournisseur** et **lieu**.

4. Analyse de la livraison et des commandes

- Délai moyen de livraison : différence entre **Ship Date** et **Order Date**.
- Mode de livraison le plus utilisé (**Ship Mode**) et impact sur le profit.

5. Relations fournisseurs / stockage

- Suivi des produits par **fournisseur** et **entrepôt**.
- Identifier les **fournisseurs critiques** pour certains produits.
- Optimiser l'affectation des produits aux lieux de stockage selon les ventes régionales.

6. Prévisions simples

- Estimation des ventes futures par produit, catégorie ou région.
- Prévision de stock nécessaire pour éviter les ruptures.

7. Performance des clients et segments

- Identifier les **top clients** (volume d'achat, fréquence).
- Analyser le comportement des **segments de clients**.

8. Analyse croisée ventes-stock

- Identifier les produits populaires mais à **faible stock**.
- Corrélation entre **promotions** / **remises** et quantité vendue.

9. Vues et alertes SQL

- Créer des **vues SQL contenant** des alertes sur les produits en rupture de stock ou à faible marge.
- Créer des **vues SQL** pour des prévisions simples de stock ou de ventes futures.

IV. Exemples d'étapes à suivre

Ceci est un simple guide pour vous orienter, vous pouvez suivre d'autres pistes.

- **Étape 1 : Compréhension des sources de données**

1. Identifier les colonnes clés du Superstore Dataset et leur signification.
2. Identifier les colonnes clés dans la base gestionstock et leur signification.
3. Vérifier s'il existe des colonnes communes permettant de relier les deux sources (ex : Product ID, Supplier ID).
4. Identifier les types de données pour chaque colonne et déterminer si une conversion est nécessaire (ex : dates, chiffres, texte).
5. Analyser la qualité des données : valeurs manquantes, doublons, incohérences, erreurs de saisie.
6. Vérifier les clés primaires et étrangères pour faciliter l'intégration des tables.

- **Étape 2 : Conception du Data Warehouse**

6. Quelles dimensions doivent être créées ?
7. Quelle sera la table de faits principale ?
8. Quel schéma utiliser : étoile ou flocon ? Pourquoi ?
9. Faut-il prévoir des SCD (Slowly Changing Dimensions) pour suivre l'historique des prix ou clients ou autres ?
10. Définir la granularité de la table de faits (par produit, par commande, par jour, etc.).
11. Déterminer les contraintes d'intégrité et index pour optimiser les requêtes OLAP.

- **Étape 3 : ETL (Extraction – Transformation – Chargement)**

11. Comment extraire les données du Superstore Dataset et de gestionstock ?
12. Quelles transformations appliquer :
 - Uniformiser les formats de date
 - Corriger les noms ou identifiants incohérents
 - Calculer de nouvelles mesures (ex: marge = Profit / Sales)
 - Corriger les valeurs manquantes ou incohérentes.
 - Effectuer les **jointures entre les sources**.
 - Etc.
13. Charger les données dans les tables du Data Warehouse ?
14. Comment valider que le chargement est correct (nombre de lignes, totaux, cohérence des clés) ?

- **Étape 4 : Analyse des données dans le Data Warehouse**

15. Chiffre d'affaires total par :
 - Produit, catégorie, sous-catégorie
 - Région, ville, État
 - Segment de client (Consumer, Corporate, Home Office)

20. Marge totale et par produit, catégorie, région.
21. Quels sont les tops clients et les tops produits ?
22. Quels produits sont populaires mais en rupture de stock ou avec faible marge ?
23. Identifier les **produits à forte vente mais faible marge**.
24. Évaluer l'impact des **remises (Discount)** sur le profit et la marge.
25. Identifier les **tops clients** et les **tops produits**.
26. Analyse du **stock** :

- Quantité disponible par produit et lieu de stockage
- Produits en rupture ou en quantité faible

25. Analyse des **livraisons et commandes** :

- Délai moyen de livraison (Ship Date – Order Date)
- Mode de livraison le plus utilisé (Ship Mode) et impact sur profit

26. Identifier les **tendances de vente dans le temps** (mois, trimestre, année).

26. Prévisions simples

- Estimation des ventes futures par produit, catégorie ou région.
- Prévisions de stock nécessaires pour éviter les ruptures.

• **Étape 5 : Création de cubes ROLAP**

27. Définir les **mesures du cube** : Sales, Quantity, Profit, Stock Disponible, Marge, etc.
28. Définir les **dimensions du cube** : Temps, Produit, Client, Région, Fournisseur, Lieu de stockage, etc.
29. Créer des **hiérarchies dans les dimensions** :
 - Temps : Année → Trimestre → Mois → Semaine → Jour
 - Région : Région → État → Ville

30. Déterminer les **filtres et slicers** pour explorer le cube.
31. Ajouter des **calculs dérivés dans le cube** : % du total, cumul, moyenne pondérée, marge %, taux de croissance, etc.

• **Étape 6 : Opérations sur les cubes ROLAP**

32. Drill-down : descendre dans les détails (ex : ventes par mois → par jour).
33. Roll-up : synthétiser les données (ex : ventes totales par région ou catégorie).
34. Slice : filtrer sur une dimension spécifique (ex : segment client ou catégorie produit).
35. Dice : combiner plusieurs dimensions (ex : Région + Produit + Mois).
36. Calculer des mesures dérivées :
 - Marge = Profit / Sales
 - Stock restant / Ventes

- Taux de croissance des ventes

37. Créer des **vues SQL** pour générer automatiquement les alertes (rupture de stock, faible marge).
38. Planifier un **batch ETL** pour automatiser la mise à jour des données et alertes.
39. Réfléchir à la création d'un **tableau de bord décisionnel** (futur travail).

V. Travail à rendre :

1. Rapport écrit

- Présentation du projet et des **objectifs du Data Warehouse**.
- Description des **sources de données** (Superstore Dataset et base gestionstock) et des **transformations appliquées** lors de l'ETL.
- Schéma du **Data Warehouse** : modèle en étoile ou en flocon, avec les tables de faits et les dimensions.
- Description des **vues créées** pour les alertes (produits en rupture ou faible marge) et les prévisions (ventes ou stock).
- Explication des **choix de métriques, agrégations et filtres** pour l'analyse OLAP.
- **Screenshots** des exécutions SQL et des résultats obtenus.

2. Scripts SQL

- Création des **tables du Data Warehouse** (tables de faits et dimensions).
- Requêtes SQL pour les **analyses OLAP demandées** (totaux des ventes, marges, tops produits, etc.).
- Création des **vues pour les alertes et les prévisions**.

3. Job Talend

- Projet complet Talend contenant les **workflows ETL** pour l'extraction, transformation et chargement des données.
- Job **exécutable**, validé sur les deux sources de données.